




BAMBOO

Brazilian E-Commerce



BAMBOO

Group members



DATA CLEANING & EDA

วัตถุประสงค์ (Objective)

- เพื่อตรวจสอบความถูกต้องและเหมาะสมของข้อมูล (Data Audit)
- เพื่อฝึกการดำเนินงาน Data Cleaning เนื้องานด้าน
- เพื่อสร้าง Visualization สำหรับการวิเคราะห์ผลสำรวจ (EDA)

DATA AUDIT & CLEANING PLAN

IMPORT LIBRARIES

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

DOWNLOAD DATASET

```
▶ import kagglehub

# Download latest version
path = kagglehub.dataset_download("olistbr/brazilian-ecommerce")

print("Path to dataset files:", path)
```

LOAD DATA

```
BZ_customers = pd.read_csv("/kaggle/input/brazilian-ecommerce/olist_customers_dataset.csv")
```

```
▶ BZ_order_dataset = pd.read_csv("/kaggle/input/brazilian-ecommerce/olist_orders_dataset.csv")
```

BZ_ORDER_DATASET.INFO()

ตรวจสอบโครงสร้างและข้อมูลที่หายไป

```
▶ BZ_order_dataset.info()  
  
... <class 'pandas.core.frame.DataFrame'>  
RangeIndex: 99441 entries, 0 to 99440  
Data columns (total 8 columns):  
 #   Column           Non-Null Count  Dtype     
---  --  
 0   order_id         99441 non-null   object    
 1   customer_id     99441 non-null   object    
 2   order_status     99441 non-null   object    
 3   order_purchase_timestamp  99441 non-null   object    
 4   order_approved_at 99281 non-null   object    
 5   order_delivered_carrier_date 97658 non-null   object    
 6   order_delivered_customer_date 96476 non-null   object    
 7   order_estimated_delivery_date 99441 non-null   object    
dtypes: object(8)  
memory usage: 6.1+ MB
```

BZ_ORDER_DATASET.DESCRIBE()

ดูสถิติเบื้องต้นของข้อมูล (แบบ TEXT)

```
▶ BZ_order_dataset.describe()  
  
...  
    order_id      customer_id  order_status  order_purchase_timestamp  order_approved_at  order_delivered_carrier_date  order_delivered_customer_date  order_estimated_delivery_date  
count      99441          99441        99441                  99441          99281                  97658                96476          99441  
unique     99441          99441        8                     98875          90733                  81018                95664          459  
top  66dea50a8b16d9b4dee7af250b4be1a5  edb027a75a1449115f6b43211ae02a24  delivered  2018-08-02 12:06:07  2018-02-27 04:31:10  2018-05-09 15:48:00  2018-05-14 20:02:44  2017-12-20 00:00:00  
freq      1                  1          96478                  3                  9                  47                  3          522
```

คำนวณเปอร์เซ็นต์ข้อมูลที่หายไป (MISSING DATA)

โค้ดนี้จะตรวจสอบทุกคอลัมในตาราง BZ_ORDER_DATASET และคำนวณว่ามีข้อมูลที่ว่าง (NULL/MISSING) อยู่กี่เปอร์เซ็นต์

```
# คำนวณเปอร์เซ็นต์ของ Missing Values ในแต่ละคอลัมน์
missing_percentage = (BZ_order_dataset.isnull().sum() / len(BZ_order_dataset)) * 100

# แสดงผลเฉพาะคอลัมน์ที่มีข้อมูลหาย
print(missing_percentage[missing_percentage > 0].sort_values(ascending=False))
```

```
order_delivered_customer_date      2.981668
order_delivered_carrier_date       1.793023
order_approved_at                  0.160899
dtype: float64
```

ผลลัพธ์แสดงให้เห็นว่ามี 3 คอลัมน์ที่มีข้อมูลหาย โดยคอลัมน์ ORDER_DELIVERED_CUSTOMER_DATE (วันที่ส่งถึงลูกค้า) มีข้อมูลหายไปมากที่สุดเกือบ 3%

แก้ไขประเภทข้อมูล (DATA TYPE CLEANING)

แก้ Data type จาก object เป็น Date time

```
▶ date_columns = ['order_purchase_timestamp', 'order_approved_at',
                  'order_delivered_carrier_date', 'order_delivered_customer_date',
                  'order_estimated_delivery_date']

for col in date_columns:
    BZ_order_dataset[col] = pd.to_datetime(BZ_order_dataset[col], errors='coerce')

BZ_order_dataset.info()

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 99441 entries, 0 to 99440
Data columns (total 8 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   order_id         99441 non-null   object  
 1   customer_id      99441 non-null   object  
 2   order_status      99441 non-null   object  
 3   order_purchase_timestamp  99441 non-null   datetime64[ns]
 4   order_approved_at 99281 non-null   datetime64[ns]
 5   order_delivered_carrier_date 97658 non-null   datetime64[ns]
 6   order_delivered_customer_date 96476 non-null   datetime64[ns]
 7   order_estimated_delivery_date 99441 non-null   datetime64[ns]
dtypes: datetime64[ns](5), object(3)
memory usage: 6.1+ MB
```

โค้ดนี้จะแปลงคอลัมน์ที่ควรจะเป็น "วันที่" (เช่น ORDER_PURCHASE_TIMESTAMP) ซึ่งปัจจุบันถูกเก็บเป็น "ข้อความ" (OBJECT) ให้กลายเป็นประเภทข้อมูล "วันที่และเวลา" (DATETIME) ที่ถูกต้อง

ผลลัพธ์: การใช้ .INFO() อีกครั้งในตอนท้าย ช่วยยืนยันว่าคอลัมน์เหล่านั้นถูกเปลี่ยนประเภทเป็น DATETIME64[NS] สำเร็จแล้ว พร้อมสำหรับการวิเคราะห์ด้านเวลาต่อไป



```
print("Missing values per column after datetime conversion:")
print(BZ_order_dataset[date_columns].isnull().sum())
```

```
... Missing values per column after datetime conversion:
order_purchase_timestamp          0
order_approved_at                 160
order_delivered_carrier_date     1783
order_delivered_customer_date    2965
order_estimated_delivery_date    0
dtype: int64
```

DATA AUDIT (CODE & OUTPUT)

- **DF.INFO():** แสดงผลและตรวจสอบ DATA TYPES (เช่น DATE เป็น OBJECT หรือไม่) และ MISSING VALUES

จากการตรวจสอบพบว่า DATA TYPES เป็น OBJECT และมีMISSING VALUES

```
# คำนวณเปอร์เซ็นต์ของ Missing Values ในแต่ละคอลัมน์
missing_percentage = (BZ_order_dataset.isnull().sum() / len(BZ_order_dataset)) * 100

# แสดงผลเฉพาะคอลัมน์ที่มีข้อมูลหาย
print(missing_percentage[missing_percentage > 0].sort_values(ascending=False))

order_delivered_customer_date    2.981668
order_delivered_carrier_date     1.793023
order_approved_at                 0.160899
dtype: float64
```

```
▶ print("Missing values per column after datetime conversion:")
print(BZ_order_dataset[date_columns].isnull().sum())

... Missing values per column after datetime conversion:
order_purchase_timestamp          0
order_approved_at                 160
order_delivered_carrier_date     1783
order_delivered_customer_date    2965
order_estimated_delivery_date     0
dtype: int64
```

- **DF.DESCRIBE():** แสดงผลและตรวจสอบค่าสถิติ (เช่น MIN, MAX) เพื่อหา OUTLIERS

BZ_order_dataset.describe()									
	order_id	customer_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estimated_delivery_date	
count	99441	99441	99441	99441	99281	97658	96476	99441	
unique	99441	99441	8	98875	90733	81018	95664	459	
top	66dea50a8b16d9b4dee7af250b4be1a5	edb027a75a1449115f6b43211ae02a24	delivered	2018-08-02 12:06:07	2018-02-27 04:31:10	2018-05-09 15:48:00	2018-05-14 20:02:44	2017-12-20 00:00:00	
freq	1	1	96478	3	9	47	3	522	

ไม่มี OUTLIERS ใน TABLE นี้

CLEANING ACTION PLAN (TEXT/MARKDOWN)

ระบุปัญหา 3-5 ข้อ ที่พบจาก DATA AUDIT (เช่น "CUSTOMERID มี MISSING 20%",
"QUANTITY มีค่าติดลบ", "UNITPRICE มี OUTLIER สูงมาก")

1. ปัญหารื่อง DATA TYPE เป็น OBJECT ไม่สามารถนำไปใช้ต่อได้
ข้อมูลของเราเป็นเวลาแต่ทำการเก็บไว้เป็น OBJECT

2. เราได้เปลี่ยนจาก DATA TYPE ที่เป็น OBJECT เป็น DATETIME จึงทำให้เกิด
MISSING ERROR เพราะอาจเกิดจาก อาจมีข้อมูลบางประเภทไม่ตรง TYPE


เสนอแผนการจัดการ (W3 ACTION PLAN): อธิบายว่าทีมของคุณจะจัดการกับปัญหาเหล่านี้อย่างไรในสัปดาห์หน้า (เช่น "ลบและที่ CUSTOMERID เป็น NULL", "ใช้ CAPPING ที่ 99TH PERCENTILE กับ QUANTITY")

1. แก้ DATA TYPE จาก OBJECT เป็น DATE TIME

2. การเปลี่ยนข้อมูลแล้วเกิด MISSING แก้โดยการเปลี่ยนค่าเป็นค่าว่าง

5 KEY VISUALIZATIONS (EDA)

DISTRIBUTION CHECK (2 граф):
HISTOGRAM หรือ BOX PLOT ของตัวแปร




คำอธิบาย: "ตรวจสอบข้อมูลซ้ำซ้อน (DUPLICATE ROWS)"

ความหมาย: โค้ดนี้ใช้เพื่อตรวจสอบว่ามีแถว (อโอดอร์) ใดในตาราง กี่มีข้อมูล "ซ้ำกันทั้งหมด" หรือไม่

สิ่งที่พบ: ผลลัพธ์คือ 0 ซึ่งหมายความว่า ไม่มีข้อมูลที่ซ้ำซ้อนกันเลย ซึ่งเป็นสัญญาณที่ดีว่าข้อมูลมีคุณภาพ (DATA QUALITY)


NUMERICAL สำหรับ 2 ตัว (เช่น MONTHLY CHARGES, TOTAL REVENUE)



คำอธิบาย: สำรวจสถานะคำสั่งซื้อ (ORDER STATUS)"

ความหมาย: โค้ดนี้ใช้เพื่อตรวจสอบว่าในคอลัมน์ ORDER_STATUS มีค่า (สถานะ) ที่ไม่ซ้ำกันอยู่ก็ตั้งหนึ่งก็แบบ และมีอะไรบ้าง

RELATIONSHIP CHECK (1 กราฟ):
CORRELATION HEATMAP และความสัมพันธ์ระหว่างตัวแปร NUMERICAL กับหมวด




คำอธิบาย: คันหา 3 อันดับแรกของคอลัมน์ที่มีข้อมูลหาย (MISSING DATA) มากที่สุด"

ความหมาย: โค้ดนี้ใช้เพื่อตรวจสอบคุณภาพข้อมูล โดยจะนับจำนวนข้อมูลที่ว่าง (NULL) ในทุกคอลัมน์ และเรียงลำดับจากมากไปน้อย

BIVARIATE COMPARISON (2 กราฟ):

BAR PLOT หรือ GROUPED BOX PLOT เพื่อเปรียบเทียบกลุ่ม

สำคัญภาพ: กราฟ 2 ชุดนี้ คือ อีสโตแกรมและ BOX PLOT กี่แสดงการกระจายตัวของข้อมูล NUMERICAL สำหรับ 2 ตัวแปร ตามลำดับ




กราฟนี้แสดงให้เห็นว่า ประสิทธิภาพการจัดส่งดีขึ้นอย่างต่อเนื่องในแต่ละปี โดยเวลาจัดส่งเฉลี่ย (เส้นกลางกล่อง) ลดลง และมีความสม่ำเสมอมากขึ้น (กล่องแคบลง) เมื่อเวลาผ่านไป

จุดสังเกตหลัก (KEY OBSERVATIONS)

แกน Y (แนวตั้ง): คือ "ระยะเวลาจัดส่ง" (ยิ่งต่ำยิ่งดี)

แกน X (แนวนอน): คือ "ปีที่สั่งซื้อ" (กลุ่มที่ใช้เปรียบเทียบ)



กราฟนี้แสดงให้เห็น การเติบโตของยอดออเดอร์ ตลอดช่วงเวลา โดยเฉพาะอย่างยิ่ง มีการเติบโตแบบก้าวกระโดด ในช่วงปลายปี 2017 จุดสังเกตหลัก (KEY OBSERVATIONS)

แกน Y (แนวตั้ง): คือ จำนวนออเดอร์ ในแต่ละเดือน

แกน X (แนวนอน): คือ ช่วงเวลา เรียงลำดับตั้งแต่ปี 2016 ไปจนถึงประมาณเดือนสิงหาคม 2018